



UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD DE INGENIERÍA

1ACC0216-Fundamentos de Data Science -16685

Trabajo Final

202610

DOCENTE

Nérida Isabel Manrique Tunque

Apellidos y Nombres	Código
Chavez Rivera, Jose antonio	U202422882
Barreda Moreno, Alonso Gabriel Enrique	U202416282
Trujillo Villa, Wilder Fabritzzio	U202414291

I. Introducción

Una empresa consultora internacional radicada en Lima solicita la elaboración de un proyecto de Ciencia de Datos con el objetivo de entender las tendencias de YouTube. Este proyecto viene a dar respuesta a los requerimientos de una empresa de marketing digital que desea tomar decisiones justificándolas con evidencias, determinando qué tipo de contenido le permite tener un mayor alcance, una mayor aceptación y una mayor interacción por parte del público en Gran Bretaña (GB).

El objetivo sería el de transformar el mismo "registro" diario de los vídeos en tendencia en conocimiento productivo, y para ello el proyecto tiene que ser capaz de determinar: qué categorías y cuáles son los canales que se encuentran en tendencia, cómo va variando a lo largo del tiempo el volumen de contenido, qué categorías son las que tiene mejor aceptación por las audiencias, y si es ya posible predecir el número de vistas que tiene un vídeo a partir de las características de sus elementos. Para poder llevarlo a cabo, se aplica la metodología CRISP-DM (Cross Industry Standard Process for Data Mining), metodología que es ampliamente utilizada en proyectos de minería de datos dado su carácter iterativo, y que también pone el énfasis en la comprensión del negocio antes de modelar.

Dada la extensión del alcance, se han considerado las siguientes fases: comprensión del negocio, comprensión de los datos, preparación de los datos, y el modelado y evaluación de los mismos; todo ello responde explícitamente a los nueve requerimientos de información que planteó el cliente.

II. Integrantes del Grupo y Roles

El equipo se organizó según los roles definidos por la metodología, asignando responsabilidades por fase del ciclo de vida del proyecto:

Integrante	Rol	Responsabilidad principal	Fase CRISP-DM
Jose Antonio Chavez Rivera	Business Project Sponsor	Definición de objetivos de negocio y criterios de éxito	1. Comprensión del negocio
jose Antonio Chavez Rivera	Data Engineer	Carga, limpieza y construcción del dataset final	2 y 3. Comprensión y preparación
Alonso Gabriel Enrique Barreda Moreno	Data Analyst	Exploración, visualizaciones y respuesta a requerimientos	2, 3 y respuestas
Trujillo Villa, Wilder Fabritzzio	Data Scientist	Selección de técnica, modelado y evaluación	4. Modelado y evaluación

III. Metodología CRISP-DM

1. Comprensión del Negocio

Esta etapa del ciclo de vida de los proyectos de minería de datos consiste en la interpretación y descripción de los objetivos y preferencias de consumo del negocio para, a continuación, convertirlas en objetivos técnicos de los datos.

OBJETIVO DEL PROYECTO

El cliente de la consultora, una empresa de marketing digital, necesita comprender qué contenido se transforma en trending en YouTube en el Reino Unido. Su finalidad es encauzar la producción de contenido de sus propios clientes, priorizar las categorías que tienen mayor alcance y aceptación, y determinar aquellos canales del mercado de referencia. A sensu stricto, el objetivo del proyecto es dar respuesta a las siguientes preguntas y realizar la estimación del conocimiento que las acompaña.

- ¿Qué categorías de videos son las de mayor tendencia, las que más y menos gustan, y cuáles tienen la mejor proporción likes/dislikes y vistas/comentarios? (Q1–Q4)
- ¿Cómo ha cambiado el volumen de videos en tendencia a lo largo del tiempo? (Q5)
- ¿Qué canales son tendencia con mayor y menor frecuencia? (Q6)
- ¿En qué estados se concentran las vistas, likes y dislikes? (Q7)
- ¿Los videos en tendencia reciben más comentarios positivos? (Q8)
- ¿Es factible predecir el número de vistas, likes o dislikes? (Q9)

Criterios de éxito. De tipo cualitativo: obtener respuestas claras y sustentadas con evidencia a cada requerimiento del cliente. De tipo cuantitativo: construir un modelo predictivo de vistas con una capacidad explicativa razonable (R^2 aceptable sobre datos de prueba).

Objetivos de Data Science

Los objetivos del negocio se traducen en metas concretas de minería de datos: un análisis descriptivo por categoría, canal y tiempo para responder Q1–Q8, y una tarea supervisada de regresión para responder Q9. Se define explícitamente la variable a modelar y sus predictores.

Variable dependiente principal:

- views (número de vistas): columna numérica que mide el alcance real de un video. Es el indicador más directo del éxito de contenido para una empresa de marketing, por lo que se selecciona como variable a predecir.

Variables independientes principales (al menos 4, incluyendo variables derivadas):

- likes y dislikes: nivel de reacción positiva y negativa de la audiencia.
- comment_count: nivel de participación e interacción del público.
- category_id: categoría temática del video.
- days_to_trend (derivada): días transcurridos entre la publicación y la fecha de tendencia.
- title_len y n_tags (derivadas): longitud del título y número de etiquetas, como indicadores de optimización del contenido.

2. Comprensión de los Datos

Esta fase comprende la recolección inicial, la descripción, la exploración y la verificación de la calidad de los datos, con el fin de familiarizarse con ellos y establecer las primeras hipótesis.

Recolectar los datos iniciales

Los datos se localizan en dos archivos entregados para el país asignado, Gran Bretaña (GB): el archivo GBvideos.csv, un registro diario de los videos de mayor tendencia en YouTube GB, y el archivo GB_category_id.json, que contiene la descripción de las categorías y permite mapear cada category_id a su nombre legible. Ambos archivos se cargan en un DataFrame de pandas para su procesamiento.

Descripción de los datos

El conjunto de datos contiene 38 916 registros y 16 columnas. Cada fila representa la aparición de un video en tendencia en una fecha determinada; existen 3 272 videos únicos, ya que un mismo video puede aparecer en tendencia durante varios días consecutivos. El periodo cubierto abarca del 14 de noviembre de 2017 al 14 de junio de 2018. La descripción de cada campo es la siguiente:

Columna	Tipo	Descripción
video_id	texto	Identificador único del video
trending_date	fecha	Fecha en que el video fue tendencia (formato yy.dd.mm)
title / channel_title	texto	Título del video y nombre del canal
category_id	entero	Identificador de categoría (se une con el JSON)
publish_time	fecha/hora	Fecha y hora de publicación del video
tags	texto	Etiquetas del video separadas por barras
views / likes / dislikes	entero	Vistas, Me gusta y No me gusta
comment_count	entero	Número de comentarios
comments_disabled / ratings_disabled	booleano	Si se deshabilitaron comentarios o valoraciones
video_error_or_removed	booleano	Si el video presentó error o fue removido
description	texto	Descripción del video

Exploración de los datos


La exploración se compone de las tareas de carga, inspección y visualización de los datos.

Cargar los datos. Los archivos se cargaron con pandas (read_csv y json.load), verificando que las 16 columnas y los 38 916 registros se importaran correctamente.

Inspeccionar los datos. Se revisó la estructura, los tipos de datos y los valores. Se construyeron tablas de frecuencia sobre las variables categóricas clave: se identificaron 16 categorías presentes en los datos y se contabilizó la frecuencia de aparición por categoría y por canal. Se detectó que la categoría con id 29 (Nonprofits & Activism) aparece en 90 registros pero no figura en el JSON de GB, por lo que se completó con el nombre estándar de la API de YouTube.

Visualizar los datos. Se elaboraron gráficos de distribución por categoría, por canal y por fecha (ver figuras 1 a 6 en la sección de requerimientos), cada uno con título y etiquetas para facilitar su interpretación.

Como parte de la exploración se analizó también la correlación entre las variables numéricas. Las vistas se correlacionan fuertemente con los likes (0,80), lo que anticipa que las reacciones serán un buen predictor del alcance.



Verificar la calidad de los datos

Se efectuaron verificaciones de consistencia, valores nulos y valores fuera de rango:

- Valores nulos: únicamente la columna description presenta 612 nulos; ninguna variable numérica clave (views, likes, dislikes, comment_count) tiene faltantes.
- Consistencia: los video_id repetidos no constituyen un error, sino el mismo video en distintos días de tendencia; se decide conservar la última aparición para las métricas por video (mayor acumulado).
- Valores fuera de rango: en la variable derivada days_to_trend se detectaron 517 registros con más de 365 días (videos antiguos que reingresan a tendencia), candidatos a tratamiento como outliers. La mediana real es de 10 días.

Limitación importante sobre la geografía. El enunciado indica que el dataset modificado incorpora las columnas state, lat y lon para responder el requerimiento 7 (vistas/likes/dislikes por Estado). El archivo GBvideos.csv entregado no contiene dichas columnas, por lo que el requerimiento 7 no puede resolverse con esta versión de los datos. Se documenta como limitación y se recomienda solicitar la versión geolocalizada del dataset.

3. Preparación de los Datos

En esta fase se preparan los datos para adaptarlos a las técnicas de minería que se aplicarán, y se responde a los requerimientos solicitados.

Limpiar los datos

Se aplicaron las siguientes operaciones de limpieza para optimizar la calidad de los datos:

- Conversión de `trending_date` (formato `yy.dd.mm`) y `publish_time` al tipo fecha, eliminando la zona horaria para permitir operaciones aritméticas.
- Unión del `category_id` con el archivo JSON para obtener el nombre legible de cada categoría.

Pre-procesar los datos

Verificar datos faltantes. Los 612 nulos de la columna `description` se completaron con cadena vacía, ya que no participa en el modelado y así se evita perder registros. Ninguna otra columna requirió imputación.

Identificación y tratamiento de datos atípicos (outliers). En la variable `days_to_trend` se identificaron 517 valores superiores a 365 días. Como técnica de tratamiento se aplicó un filtrado por rango (0 a 365 días) exclusivamente para la fase de modelado, evitando que estos valores extremos distorsionen la relación entre variables sin eliminar información del análisis descriptivo.

Construir nuevos datos

A partir de las columnas existentes se generaron nuevas variables (derivación de atributos):

- `days_to_trend`: diferencia en días entre `trending_date` y `publish_time`.
- `title_len`: longitud del título en caracteres.
- `n_tags`: número de etiquetas del video.
- `pub_hour`: hora de publicación extraída de `publish_time`.


Adicionalmente se generó un conjunto por video único (conservando la última aparición de cada `video_id`) para las métricas comparativas por categoría, y se exportó el conjunto de datos limpio y enriquecido como `GBvideos_clean.csv`, listo para el análisis y el modelado.

Requerimientos

A partir del conjunto de datos limpio, a continuación se da respuesta a los requerimientos solicitados por el cliente. Cada respuesta se acompaña de su visualización correspondiente.


Q1. ¿Qué categorías son las de mayor tendencia?

Medido por número de apariciones en tendencia, Music domina ampliamente (13 754 apariciones), seguida de Entertainment (9 124) y People & Blogs (2 926). La música y el entretenimiento concentran más del 58 % de todo el contenido en tendencia en GB.




Q2. ¿Qué categorías gustan más y cuáles menos?

Por promedio de "Me gusta" por video único, Nonprofits & Activism lidera (≈357 mil likes promedio) seguida de Music (≈254 mil). Las que menos gustan en promedio son Travel & Events (≈9,7 mil), News & Politics (≈15,5 mil) y Sports (≈17,4 mil).




Q3. Mejor ratio Me gusta / No me gusta

Shows presenta la mejor proporción (≈124 likes por cada dislike), seguida de Pets & Animals (≈41) y Howto & Style (≈30). Un ratio alto indica contenido con recepción muy positiva y baja controversia.



Q4. Mejor ratio Vistas / Comentarios

Travel & Events encabeza con ≈ 923 vistas por comentario, seguida de Music (≈ 662) y Film & Animation (≈ 564). Un ratio alto sugiere contenido muy visto pero que genera comparativamente poca conversación.




Q5. Evolución del volumen de videos en tendencia

El número de videos en tendencia por día se mantiene relativamente estable a lo largo del periodo (típicamente entre 190 y 200 videos diarios), reflejando la naturaleza de la lista de tendencias de tamaño fijo, con ligeras variaciones asociadas a picos de eventos.



Q6. Canales más y menos frecuentes en tendencia

Los programas nocturnos y de entretenimiento dominan: The Tonight Show Starring Jimmy Fallon (208 apariciones), TheEllenShow (207), Jimmy Kimmel Live (207), Saturday Night Live (206) y WWE (205). En el extremo opuesto, miles de canales aparecen una sola vez, evidenciando una distribución de cola larga.



Q7. Vistas, Me gusta y No me gusta por Estado

No es posible responder esta pregunta porque el conjunto de datos no cuenta con información geográfica. El archivo GBvideos.csv no incluye ninguna columna de ubicación (como state, lat o lon), por lo que no se pueden agrupar las vistas, likes y dislikes por Estado.

Q8. ¿Los videos en tendencia reciben más comentarios positivos?

No es posible responder esta pregunta porque el conjunto de datos solo indica la cantidad de comentarios (comment_count), pero no el texto de los mismos. Sin el contenido de los comentarios, no se puede analizar si son positivos o negativo

Q9. ¿Es factible predecir el número de Vistas?

Sí es factible. Se planteó una tarea supervisada de regresión sobre $\log(\text{views})$. Los resultados de la evaluación se presentan en la siguiente sección.

IV. Modelado y Evaluación de Resultados

En esta fase se establecen las técnicas de modelado más apropiadas para el proyecto de acuerdo con los objetivos planteados, y se evalúa el rendimiento del modelo obtenido.

Escoger la técnica de modelado

Al tratarse de un problema de predicción de una variable numérica continua (vistas), se seleccionaron dos técnicas de regresión: Regresión Lineal como modelo base interpretable, y Random Forest como modelo no lineal capaz de capturar interacciones entre variables. La variable objetivo se transformó a escala logarítmica $-\log(1+\text{views})$ para reducir el fuerte sesgo de la distribución de vistas.

Generar el plan de prueba

Los datos se dividieron en dos conjuntos: 75 % para entrenamiento y 25 % para prueba (`train_test_split`, `random_state=42`). La calidad del modelo se evaluó con el coeficiente de determinación R^2 y el error absoluto medio (MAE) en escala logarítmica, medidos sobre el conjunto de prueba para estimar la capacidad de generalización.

Construir el modelo


Se ejecutaron ambas técnicas sobre los datos preparados, usando como predictores: `likes`, `dislikes`, `comment_count`, `days_to_trend`, `title_len`, `n_tags`, `pub_hour` y `category_id`. El Random Forest se configuró con 120 árboles y profundidad máxima de 18.

Evaluar el modelo


Resultados de la evaluación sobre el conjunto de prueba:

Modelo	R^2 (test)	MAE (log, test)
Regresión Lineal	0.402	1.169
Random Forest	0.986	0.122

El Random Forest explica el 98,6 % de la variabilidad de las vistas en el conjunto de prueba, superando ampliamente a la regresión lineal (40,2 %). El análisis de importancia de variables muestra que `likes` (0,75) y `dislikes` (0,16) son, con diferencia, los predictores más influyentes: el volumen de reacciones está fuertemente asociado al alcance del video. Las variables derivadas (`title_len`, `n_tags`, `days_to_trend`) aportan de forma marginal pero consistente.



Nota: Valores reales vs. predichos del modelo Random Forest (escala logarítmica). La cercanía de los puntos a la diagonal indica un buen ajuste.



Nota: Importancia de las variables en el modelo Random Forest.

V. Conclusiones

1 Conclusiones de negocio

- Music y Entertainment dominan las tendencias en GB (>58 % del contenido); son las categorías prioritarias para maximizar alcance.
- Las categorías que más gustan en promedio son Nonprofits & Activism y Music; Travel & Events y News & Politics son las de menor aceptación relativa.
- Shows y Pets & Animals ofrecen la mejor proporción likes/dislikes: contenido de recepción positiva y baja controversia, ideal para asociación de marca.
- Los canales de programas nocturnos (Fallon, Ellen, Kimmel, SNL) son referentes recurrentes de tendencia y candidatos naturales para colaboraciones.
- Es factible predecir las vistas con alta precisión ($R^2=0,986$); las reacciones de la audiencia son el principal impulsor del alcance.

2 Conclusiones técnicas

La calidad del dataset es alta (casi sin nulos en variables clave). La transformación logarítmica y el filtrado de outliers en days_to_trend fueron decisivos para el modelado. El Random Forest superó claramente a la regresión lineal, evidenciando relaciones no lineales entre las variables.

3 Limitaciones

- El dataset entregado carece de las columnas geográficas, impidiendo responder el requerimiento 7.
- No hay texto de comentarios, por lo que el requerimiento 8 no puede resolverse mediante análisis de sentimiento.
- Los datos de Estado, cuando existen, son simulados aleatoriamente según el enunciado, por lo que cualquier conclusión geográfica sería referencial.
- El fuerte peso de likes en el modelo genera cierta circularidad (las reacciones acompañan a las vistas); un modelo puramente predictivo previo a la publicación requeriría excluir métricas posteriores.

4 Trabajo futuro

- Incorporar la versión geolocalizada del dataset y elaborar mapas con GeoPandas/Plotly (Q7).
- Realizar análisis de sentimiento sobre el texto de los comentarios (Q8).
- Construir un modelo predictivo "pre-publicación" usando solo atributos conocibles antes de publicar (categoría, hora, título, tags).
- Análisis de texto de títulos y tags para identificar palabras clave asociadas a tendencia.

5 link de githu: <https://github.com/jozzzes01/FDS-2026-1-16310>

VI. Bibliografía

Google. (s. f.). *Google Trends*. <https://trends.google.com/>

Google Developers. (s. f.). *YouTube Data API*. <https://developers.google.com/youtube>

IBM. (s. f.). *What is data science?* <https://www.ibm.com/topics/data-science>

Matplotlib Development Team. (s. f.). *Matplotlib documentation*.
<https://matplotlib.org/stable/>

Microsoft. (s. f.). *Microsoft Learn: Azure Machine Learning*.
<https://learn.microsoft.com/training/browse/?products=azure-machine-learning>